logo

TASCA 12 - IT Academy

Curs Data Science

In [137…
```python
import pandas as pd
import numpy as np
from numpy import random
import pandas as pd
from datetime import datetime
import statistics as stat
import seaborn as sns
import matplotlib.pyplot as plt
from matplotlib.pyplot import figure
from pyod.models.knn import KNN
from sklearn.preprocessing import StandardScaler
from sklearn.preprocessing import MinMaxScaler
import sklearn
from sklearn.decomposition import PCA
import sklearn.neighbors
from sklearn.neighbors import kneighbors_graph
from sklearn.datasets import make_blobs
from sklearn.model_selection import train_test_split

pd.options.display.float_format = '{:.0f}'.format
```

Exercici 1.

Parteix el conjunt de dadesDelayedFlights.csv en train i test. Estudia els dos conjunts per separat, a nivell descriptiu: __[X] Fet__

In [158…
```python
file=pd.read_csv("DelayedFlights.csv", sep=",", encoding='utf8')
```

In [139…
```python
file.head()
```

Out[139…

	Unnamed: 0	Year	Month	DayofMonth	DayOfWeek	DepTime	CRSDepTime	ArrTime	CRSArrTime	UniqueCarrier	...	TaxiIn	TaxiOut	Canc
0	0	2008	1	3	4	2003	1955	2211	2225	WN	...	4	8	
1	1	2008	1	3	4	754	735	1002	1000	WN	...	5	10	
2	2	2008	1	3	4	628	620	804	750	WN	...	3	17	
3	4	2008	1	3	4	1829	1755	1959	1925	WN	...	3	10	
4	5	2008	1	3	4	1940	1915	2121	2110	WN	...	4	10	

5 rows × 30 columns

In [140…
```python
file.describe().round(2)
```

Out[140…

	Unnamed: 0	Year	Month	DayofMonth	DayOfWeek	DepTime	CRSDepTime	ArrTime	CRSArrTime	FlightNum	...	Distance	Tax
count	1936758	1936758	1936758	1936758	1936758	1936758	1936758	1929648	1936758	1936758	...	1936758	19296
mean	3341651	2008	6	16	4	1519	1467	1610	1634	2184	...	766	
std	2066065	0	3	9	2	450	425	548	465	1945	...	574	
min	0	2008	1	1	1	1	0	1	0	1	...	11	
25%	1517452	2008	3	8	2	1203	1135	1316	1325	610	...	338	
50%	3242558	2008	6	16	4	1545	1510	1715	1705	1543	...	606	
75%	4972467	2008	9	23	6	1900	1815	2030	2014	3422	...	998	
max	7009727	2008	12	31	7	2400	2359	2400	2400	9742	...	4962	2

8 rows × 25 columns

In [141…
```python
file.shape
```

Out[141…
```
(1936758, 30)
```

In [142…
```python
file.columns
```

Out[142…
```
Index(['Unnamed: 0', 'Year', 'Month', 'DayofMonth', 'DayOfWeek', 'DepTime',
       'CRSDepTime', 'ArrTime', 'CRSArrTime', 'UniqueCarrier', 'FlightNum',
       'TailNum', 'ActualElapsedTime', 'CRSElapsedTime', 'AirTime', 'ArrDelay',
       'DepDelay', 'Origin', 'Dest', 'Distance', 'TaxiIn', 'TaxiOut',
       'Cancelled', 'CancellationCode', 'Diverted', 'CarrierDelay',
       'WeatherDelay', 'NASDelay', 'SecurityDelay', 'LateAircraftDelay'],
      dtype='object')
```

In [143…
```python
# A continuación, vemos que la columna 'Unnamed' no aporta nada, no es más que un contador de filas, así que pa
# eliminarla.

file['Unnamed: 0'].value_counts()
```

Out[143…
```
0          1
6846151    1
2232597    1
5967571    1
2242832    1
          ..
4495774    1
6925369    1
3917269    1
3919316    1
2047       1
Name: Unnamed: 0, Length: 1936758, dtype: int64
```

In [144…
```python
file.drop(['Unnamed: 0'], axis=1, inplace=True)
```

In [145…
```python
# Miramos los valores NaN que tienen las columnas

total_nan_values = file.isna().sum()
print ("Total Number of NaN values: "+'\n'+str(total_nan_values))
```

```
Total Number of NaN values:
Year                      0
Month                     0
DayofMonth                0
DayOfWeek                 0
DepTime                   0
CRSDepTime                0
ArrTime                7110
CRSArrTime                0
UniqueCarrier             0
FlightNum                 0
TailNum                   5
ActualElapsedTime      8387
CRSElapsedTime          198
AirTime                8387
ArrDelay               8387
DepDelay                  0
Origin                    0
Dest                      0
Distance                  0
TaxiIn                 7110
TaxiOut                 455
Cancelled                 0
CancellationCode          0
Diverted                  0
CarrierDelay         689270
WeatherDelay         689270
NASDelay             689270
SecurityDelay        689270
LateAircraftDelay    689270
dtype: int64
```

In [146…
```python
# Vamos a tratar los valores NaN de dos maneras: las columnas que representa una hora concreta ('ArrTime') o el
# una compañía aérea ('TailNum') las vamos a borrar (solo representan un 0.3% del total de los datos); las colu
# en minutos, vamos a sustituir los NaN's por la media aritmética.

file = file.dropna(subset=['ArrTime', 'TailNum'])
```

In [147…
```python
# Sustituimos los datos NaN por la media aritmética

#file=file.fillna(file.mean())
```

In [148…
```python
file.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 1929645 entries, 0 to 1936757
Data columns (total 29 columns):
 #   Column             Dtype
---  ------             -----
 0   Year               int64
 1   Month              int64
 2   DayofMonth         int64
 3   DayOfWeek          int64
 4   DepTime            float64
 5   CRSDepTime         int64
 6   ArrTime            float64
 7   CRSArrTime         int64
 8   UniqueCarrier      object
 9   FlightNum          int64
 10  TailNum            object
 11  ActualElapsedTime  float64
 12  CRSElapsedTime     float64
 13  AirTime            float64
 14  ArrDelay           float64
 15  DepDelay           float64
 16  Origin             object
 17  Dest               object
 18  Distance           int64
 19  TaxiIn             float64
 20  TaxiOut            float64
 21  Cancelled          int64
 22  CancellationCode   object
 23  Diverted           int64
 24  CarrierDelay       float64
 25  WeatherDelay       float64
 26  NASDelay           float64
 27  SecurityDelay      float64
 28  LateAircraftDelay  float64
dtypes: float64(14), int64(10), object(5)
memory usage: 441.7+ MB
```

In [149…
```python
# Pasamos a GRAFICAR: a través de la matriz de correlación podemos ver cómo algunas de las 29 variables del cor
# presentan multicolinealidad, es decir, pueden predecirse linealmente a partir de las demás.
```

In [150…
```python
# Matriz de correlación  #

corrmat = file.corr()
f, ax = plt.subplots(figsize=(12, 9))
sns.heatmap(corrmat, vmax=.8, square=True);
plt.show()
```

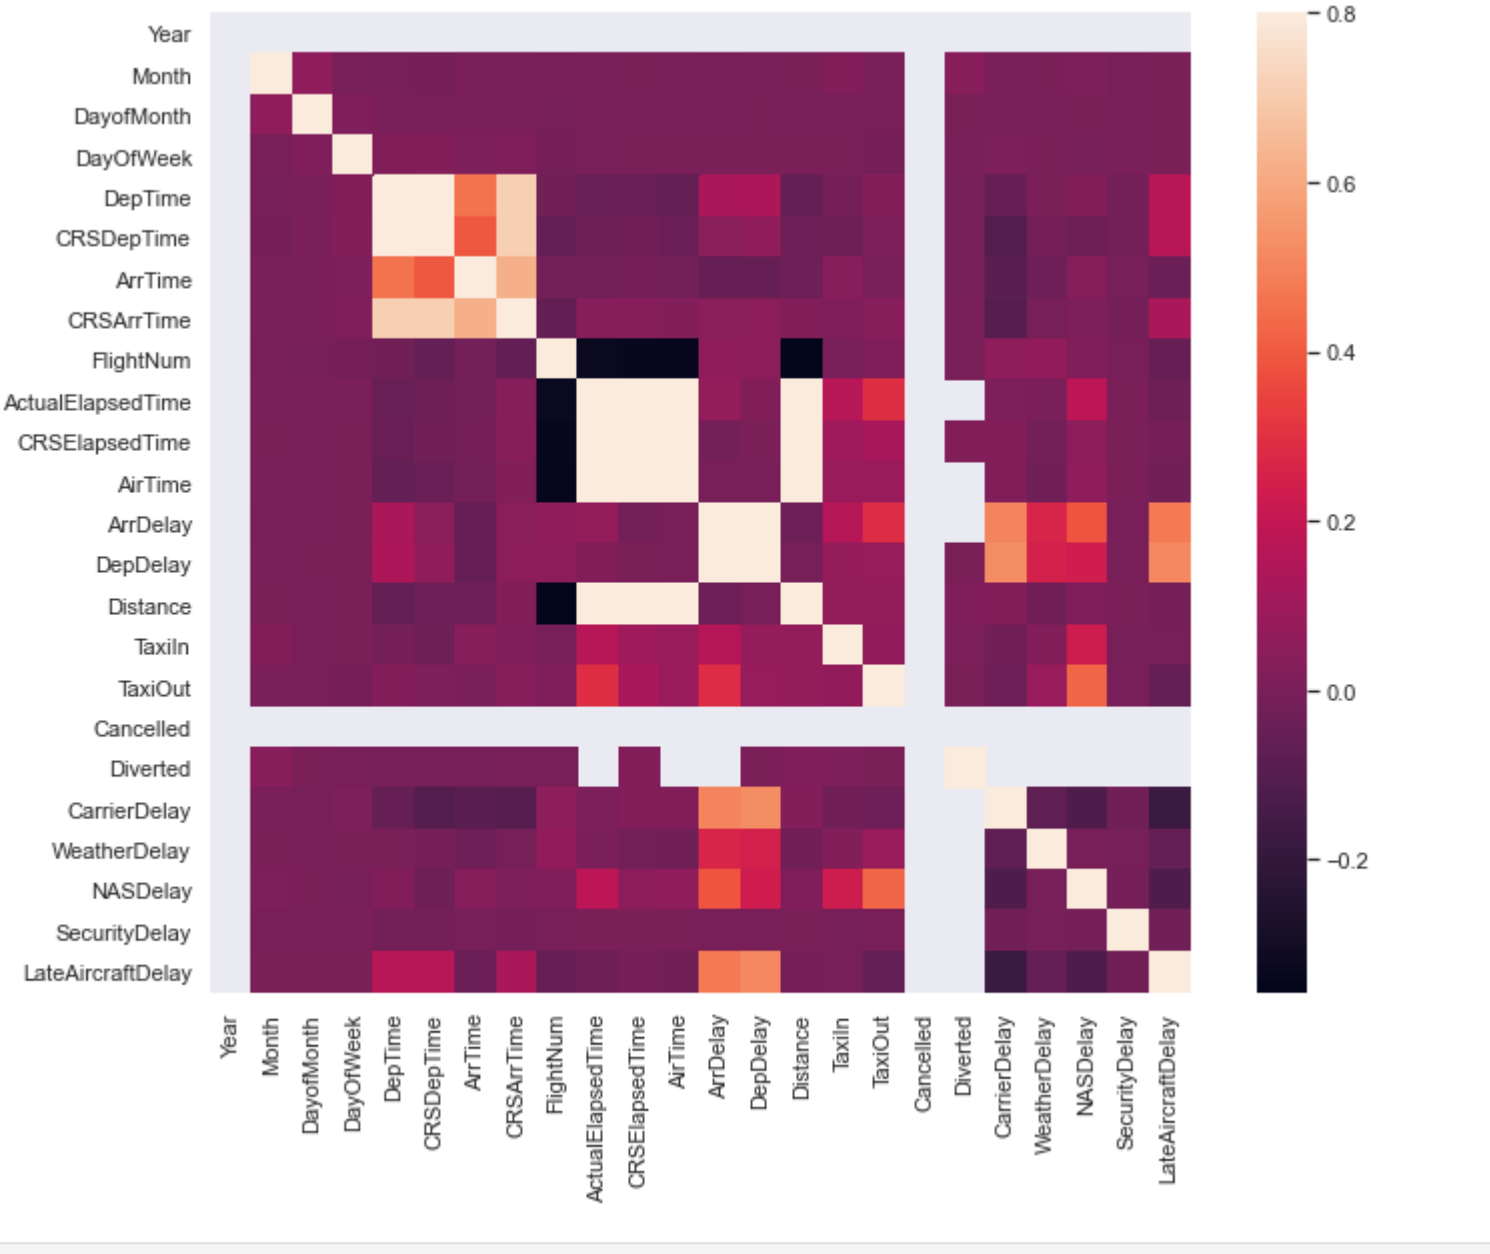

In [151…
```python
# Scatterplot #

# La matriz de correlación anterior indentifica las tres variables principales que generan los retrasos: Late A
# Carrier Delay and NAS Delay. El scatterplot corrobora este supuesto, mostrando cómo esas tres variables crean
# los retrasos durante el año.

# Antes de graficar, creamos la columna Status que representa si el vuela llegó en hora (0), con un poco retras
# con mucho retrasado (2), desviado (3) o cancelado (4)

for dataset in file:
    file.loc[file['ArrDelay'] <= 15, 'Status'] = 0
    file.loc[file['ArrDelay'] >= 15, 'Status'] = 1
    file.loc[file['ArrDelay'] >= 60, 'Status'] = 2
    file.loc[file['Diverted'] == 1, 'Status'] = 3
    file.loc[file['Cancelled'] == 1, 'Status'] = 4

sns.set()
Delayedflights = file[(file.Status >= 1) & (file.Status < 3)]
cols = ['ArrDelay', 'CarrierDelay', 'LateAircraftDelay', 'NASDelay', 'WeatherDelay']
sns.pairplot(Delayedflights[cols], size = 2.5)
plt.show()
```

```
c:\users\marta\appdata\local\programs\python\python37\lib\site-packages\seaborn\axisgrid.py:1969: UserWarning:
The `size` parameter has been renamed to `height`; please update your code.
  warnings.warn(msg, UserWarning)
```

In [152…
```python
# Una vez realizada una pequeña exploración inicial, pasamos a dividir el dataframe con el método train_test_sp

train, test = train_test_split(file, test_size = 0.30, random_state=4)

print("Ejemplos usados para Train: ", len(train))
print("Ejemplos usados para Test: ", len(test))
```

```
Ejemplos usados para Train:  1350751
Ejemplos usados para Test:  578894
```

In [153…
```python
train.describe().round(2)
```

Out[153…

	Year	Month	DayofMonth	DayOfWeek	DepTime	CRSDepTime	ArrTime	CRSArrTime	FlightNum	ActualElapsedTime	...	TaxiIn
count	1350751	1350751	1350751	1350751	1350751	1350751	1350751	1350751	1350751	1349869	...	1350751
mean	2008	6	16	4	1519	1468	1610	1634	2184	133	...	7
std	0	3	9	2	450	425	548	465	1944	72	...	5
min	2008	1	1	1	1	0	1	0	1	15	...	0
25%	2008	3	8	2	1203	1135	1316	1325	611	80	...	4
50%	2008	6	16	4	1545	1510	1715	1705	1543	116	...	6
75%	2008	9	23	6	1900	1815	2030	2014	3422	165	...	8
max	2008	12	31	7	2400	2359	2400	2359	9740	1114	...	240

8 rows × 25 columns

In [154…
```python
test.describe().round(2)
```

Out[154…

	Year	Month	DayofMonth	DayOfWeek	DepTime	CRSDepTime	ArrTime	CRSArrTime	FlightNum	ActualElapsedTime	...	TaxiIn	T
count	578894	578894	578894	578894	578894	578894	578894	578894	578894	578499	...	578894	5
mean	2008	6	16	4	1519	1468	1610	1634	2185	133	...	7	
std	0	3	9	2	451	425	548	465	1946	72	...	5	
min	2008	1	1	1	1	0	1	0	1	14	...	0	
25%	2008	3	8	2	1203	1135	1315	1325	610	80	...	4	
50%	2008	6	16	4	1545	1510	1715	1706	1543	116	...	6	
75%	2008	9	23	6	1901	1815	2031	2015	3423	165	...	8	
max	2008	12	31	7	2400	2359	2400	2359	9741	790	...	200	

8 rows × 25 columns

Exercici 2.

Aplica algun procés de transformació (estandaritzar les dades numèriques, crear columnes dummies, polinomis...): __[X] Fet__

In [ ]:
```python
# VAMOS A NORMALIZAR EL ATRIBUTO CATEGÓRICO CANCELLATIONCODE CON LA FUNCIÓN DUMMY #
```

In [159…
```python
file['CancellationCode'].value_counts()
```

Out[159…
```
N    1936125
B        307
A        246
C         80
Name: CancellationCode, dtype: int64
```

In [160…
```python
cancelCode_dummy= pd.get_dummies(file["CancellationCode"])
```

In [161…
```python
cancelCode_dummy.head(3)
```

Out[161…

	A	B	C	N
0	0	0	0	1
1	0	0	0	1
2	0	0	0	1

In [162…
```python
cancelCode_dummy.rename(columns = {'A':'CancellationCarrier', 'B':'CancellationWeather',
                                   'C':'Cancellation_NAS'}, inplace = True)
```

In [ ]:
```python
# Eliminamos la columna CancellationCode y procederemos a continuación a concatenar el nuevo DF cancelCode_dumm

file=file.drop('CancellationCode', axis='columns')
```

In [168…
```python
# Comprobamos que la columna CancellationCode ya no está en el DF

file.columns
```

Out[168…
```
Index(['Unnamed: 0', 'Year', 'Month', 'DayofMonth', 'DayOfWeek', 'DepTime',
       'CRSDepTime', 'ArrTime', 'CRSArrTime', 'UniqueCarrier', 'FlightNum',
       'TailNum', 'ActualElapsedTime', 'CRSElapsedTime', 'AirTime', 'ArrDelay',
       'DepDelay', 'Origin', 'Dest', 'Distance', 'TaxiIn', 'TaxiOut',
       'Cancelled', 'Diverted', 'CarrierDelay', 'WeatherDelay', 'NASDelay',
       'SecurityDelay', 'LateAircraftDelay'],
      dtype='object')
```

In [169…
```python
# Por último, concatenamos ambos DF's para trabajar con un único dataset

file_= pd.concat([file, cancelCode_dummy], axis=1)
file_.head(3)
```

Out[169…

	Unnamed: 0	Year	Month	DayofMonth	DayOfWeek	DepTime	CRSDepTime	ArrTime	CRSArrTime	UniqueCarrier	...	Diverted	CarrierDelay
0	0	2008	1	3	4	2003	1955	2211	2225	WN	...	0	NaN
1	1	2008	1	3	4	754	735	1002	1000	WN	...	0	NaN
2	2	2008	1	3	4	628	620	804	750	WN	...	0	NaN

3 rows × 33 columns

In [170…
```python
file_.columns
```

Out[170…
```
Index(['Unnamed: 0', 'Year', 'Month', 'DayofMonth', 'DayOfWeek', 'DepTime',
       'CRSDepTime', 'ArrTime', 'CRSArrTime', 'UniqueCarrier', 'FlightNum',
       'TailNum', 'ActualElapsedTime', 'CRSElapsedTime', 'AirTime', 'ArrDelay',
       'DepDelay', 'Origin', 'Dest', 'Distance', 'TaxiIn', 'TaxiOut',
       'Cancelled', 'Diverted', 'CarrierDelay', 'WeatherDelay', 'NASDelay',
       'SecurityDelay', 'LateAircraftDelay', 'CancellationCarrier',
       'CancellationWeather', 'Cancellation_NAS', 'N'],
      dtype='object')
```

In [64]:
```python
# VAMOS A NORMALIZAR LOS ATRIBUTOS NUMÉRICOS ARRDELAY Y DEPDELAY CON STANDARDSCALER #
```

In [171…
```python
file_ss=file[['ArrDelay', 'DepDelay']].copy()
```

In [172…
```python
ss = StandardScaler()
file_transformed = ss.fit_transform(file_ss)
file_transformed
```

Out[172…
```
array([[-0.98970118, -0.65886773],
       [-0.70793514, -0.45288482],
       [-0.49661061, -0.65886773],
       ...,
       [ 1.00027146,  0.68938404],
       [-0.5846625 , -0.60269057],
       [-0.83120778, -0.67759345]])
```

In [173…
```python
file_transformed = pd.DataFrame(file_transformed)
```

In [174…
```python
file_transformed.head(3)
```

Out[174…

	0	1
0	-1	-1
1	-1	-0
2	-0	-1

In [175…
```python
file_transformed.rename(columns = {0:'ArrDelay', 1:'DepDelay'}, inplace = True)
```

In [176…
```python
file_transformed.head(3)
```

Out[176…

	ArrDelay	DepDelay
0	-1	-1
1	-1	-0
2	-0	-1

In [177…
```python
file_ok=file_.drop(['ArrDelay', 'DepDelay'], axis='columns')
```

In [178…
```python
file_scaled= pd.concat([file_ok, file_transformed], axis=1)
file_scaled.head()
```

Out[178…

	Unnamed: 0	Year	Month	DayofMonth	DayOfWeek	DepTime	CRSDepTime	ArrTime	CRSArrTime	UniqueCarrier	...	WeatherDelay	NASDe
0	0	2008	1	3	4	2003	1955	2211	2225	WN	...	NaN	N
1	1	2008	1	3	4	754	735	1002	1000	WN	...	NaN	N
2	2	2008	1	3	4	628	620	804	750	WN	...	NaN	N
3	4	2008	1	3	4	1829	1755	1959	1925	WN	...	0	
4	5	2008	1	3	4	1940	1915	2121	2110	WN	...	NaN	N

5 rows × 33 columns

In [179…
```python
file_scaled.columns
```

Out[179…
```
Index(['Unnamed: 0', 'Year', 'Month', 'DayofMonth', 'DayOfWeek', 'DepTime',
       'CRSDepTime', 'ArrTime', 'CRSArrTime', 'UniqueCarrier', 'FlightNum',
       'TailNum', 'ActualElapsedTime', 'CRSElapsedTime', 'AirTime', 'Origin',
       'Dest', 'Distance', 'TaxiIn', 'TaxiOut', 'Cancelled', 'Diverted',
       'CarrierDelay', 'WeatherDelay', 'NASDelay', 'SecurityDelay',
       'LateAircraftDelay', 'CancellationCarrier', 'CancellationWeather',
       'Cancellation_NAS', 'N', 'ArrDelay', 'DepDelay'],
      dtype='object')
```

In [180…
```python
file_scaled.shape
```

Out[180…
```
(1936758, 33)
```

Exercici 3.

Resumeix les noves columnes generades de manera estadística i gràfica: __[X] Fet__

In [ ]:
```python
# COLUMNAS DUMMIES #
```

In [181…
```python
# Las columnas generadas con dummies son columnas con datos binarios, es decir, con valores 0 o 1. Por tanto, y
# continuación, su resumen estadístico se basan en establecer su valor mín, que obviamente es cero, el valor má
# y contar el número de valores. Vemos que no existe media, ni desviación estándar, ni cuartiles en las columna

file_scaled['CancellationWeather'].describe()
```

Out[181…
```
count   1936758
mean          0
std           0
min           0
25%           0
50%           0
75%           0
max           1
Name: CancellationWeather, dtype: float64
```

In [182…
```python
# Gráficamente, al representar una columna dummy, vemos que simplemente se representan valores absolutos (0 y 1
# he querido comparar las cancelaciones causadas por problemas meteorológicos (X) versus el total de cancelacio

x = file_scaled['CancellationWeather']
y = file_scaled['Cancelled']

plt.subplots(figsize=(10, 7))
plt.xlabel('Cancelaciones por causas climatológicas', size=16)
plt.ylabel('Total de cancelaciones', size=16)
plt.plot(x,y,'*',markersize=20, color='green')
```

Out[182…
```
[<matplotlib.lines.Line2D at 0x247575f9b48>]
```

In [77]:
```python
# Para representar un gráfico que nos proporcione información con las columnas dummies que hemos creado, por ej
# cancelaciones han sido causadas por problemas meteorológicos, cuales por problemas de la compañía aérea y cua
# (National Air System de USA) vamos a tener que trabajar un poco más... utilizaremos un pieplot.
```

In [185…
```python
# Contamos el números de vuelos totales cancelados con código de "Motivo de cancelación" y los pasamos a DF

NAS=(file_scaled['Cancellation_NAS'].value_counts()).to_list()
Weather=(file_scaled['CancellationWeather'].value_counts()).to_list()
Carrier=(file_scaled['CancellationCarrier'].value_counts()).to_list()
```

In [186…
```python
# A continuación pasamos los datos de cada motivo de cancelación a lista, y hacemos una lista total que incluye
# vuelos de cancelados por cada causa. Y por último, graficamos.


NAS=NAS[1:]
NAS
```

Out[186…
```
[80]
```

In [187…
```python
Weather=Weather[1:]
Weather
```

Out[187…
```
[307]
```

In [188…
```python
Carrier=Carrier[1:]
Carrier
```

Out[188…
```
[246]
```

In [189…
```python
DF=NAS+Weather+Carrier
```

In [194…
```python
# PiePlot #

mylabels = ["Problemas del National Air System",'Causas Climatológicas', 'Problemas de la Aerolínea']
plt.title('Motivos de cancelación de los vuelos', fontsize=20)
plt.rcParams["figure.figsize"] = (10, 6)
myexplode = [0, 0.2, 0, ]
fig=plt.pie(DF, autopct='%1.1f%%', labels=mylabels, explode= myexplode)
plt.legend(title = "Motivos de cancelación:", fontsize= 13, loc = 'right', bbox_to_anchor = (1, -0.1, 1, 1))
plt.show()
```

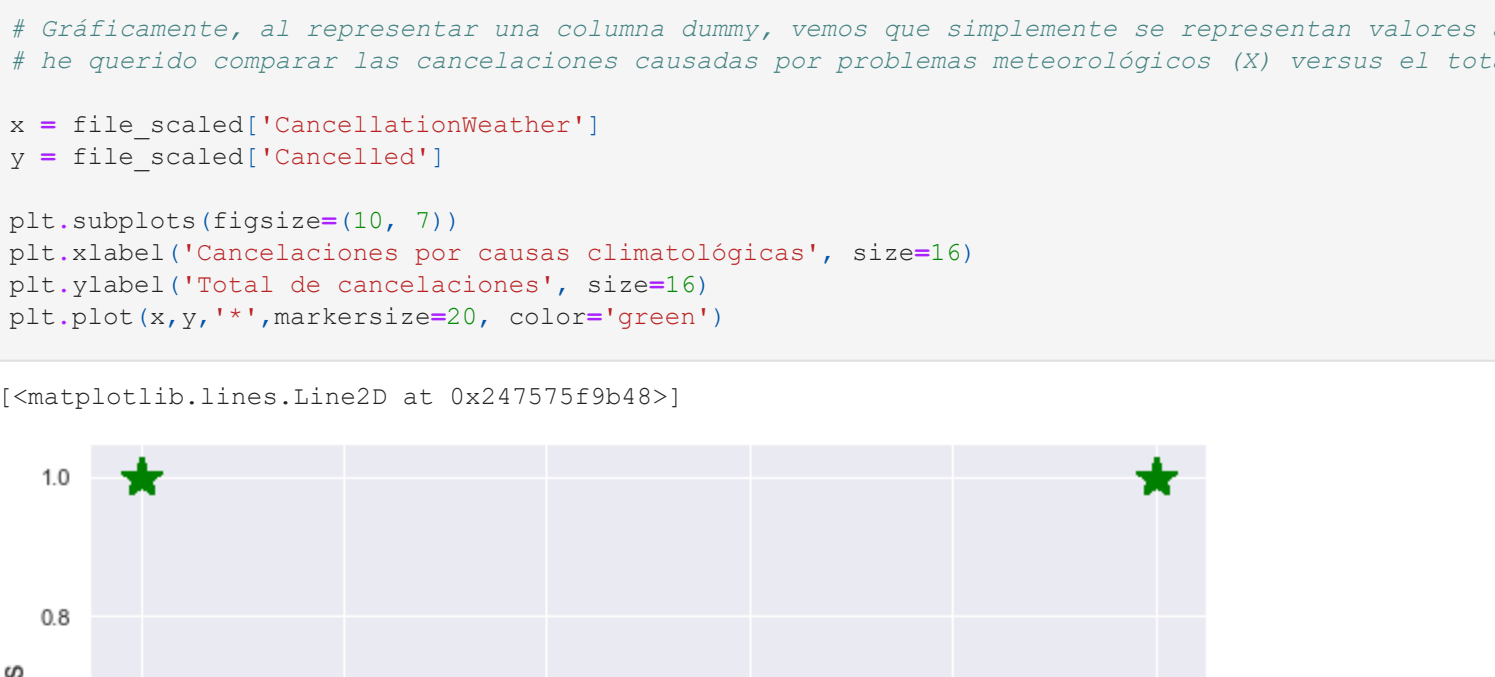

In [ ]:
```python
# COLUMNAS ESTANDARIZADAS CON STANDARSCALER #
```

In [ ]:
```python
# Cuando realizamos estandarización de valores numéricos, a diferencia que ocurre con la normalización de valor
# con dummy, vemos que el resumen estadítico no muestra que se traten de variables con valores binarios, sino c
# media, deviación estándar, los cuartiles, valores mínimos y máximos, etc. y podremos operar con ellos como si
# absolutos se trataran.
```

In [215…
```python
pd.options.display.float_format = '{:.2f}'.format

file_scaled['ArrDelay'].describe(), file_scaled['DepDelay'].describe()
```

Out[215…
```
(count   1928371.00
 mean         -0.00
 std           1.00
 min          -2.66
 25%          -0.58
 50%          -0.32
 75%           0.24
 max          42.60
 Name: ArrDelay, dtype: float64,
 count   1936758.00
 mean          0.00
 std           1.00
 min          -0.70
 25%          -0.58
 50%          -0.36
 75%           0.18
 max          45.39
 Name: DepDelay, dtype: float64)
```

In [226…
```python
# Fent el gràfic observem que hi ha una correlació lineal entre sortir tard y arribar tard en destí.

y=file_scaled['ArrDelay']
x=file_scaled['DepDelay']

plt.plot(x,y, 'r*', alpha= 0.4, markersize=15)
plt.ylabel('Retard a l´arribada', fontsize=15)
plt.xlabel('Retard a la sortida', fontsize=15)
plt.title('Correlació entre sortir tard i arribar tard', fontsize=20)
plt.show()
```

Exercici 4.

Exporta el Notebook com a pdf i com a html: __[X] Fet__

In [190…
```python
python -m pip install -U notebook-as-pdf
pyppeteer-install
```

```
  File "<ipython-input-190-5dc623094454>", line 1
    python -m pip install -U notebook-as-pdf
              ^
SyntaxError: invalid syntax
```

In [ ]:
```python
jupyter-nbconvert --to pdfviahtml Tasca12.ipynb
```